Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №1 по курсу «Информационный поиск»

«Добыча корпуса документов»

Студент: В. О. Горячкин
Преподаватель: А. А. Кухтичев
Группа: М8О-407Б-23
Дата: 19.09.2026
Оценка:
Подпись:

Москва, 2026

Лабораторная работа №1 «Добыча корпуса документов»

Необходимо подготовить корпус документов, который будет использован при выполнении остальных лабораторных работ:

1. Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
2. Разбить на документы.
3. Выделить текст.

Источников в итоговом индексе должно быть не менее двух. Нужно найти существующие поисковики, по которым уже можно искать в выбранном наборе документов, привести примеры запросов и указать недостатки выдачи.

В результатах работы должна быть указана статистика корпуса: размер «сырых» документов, количество документов, размер выделенного текста, средний размер документа и средний объём текста в документе.

1 Корпус и его характеристики

Тематика корпуса — **кино и сериалы**: фильмы, сериалы, мультфильмы и кинематографические персоналии. Источника два:

- **ru.wikipedia.org** — энциклопедические статьи о фильмах, сериалах и кинематографистах;
- **www.kino-teatr.ru** — карточки фильмов, биографии актёров, авторские статьи и обзоры.

Из чего состоит текст

Википедия, кодировка UTF-8. Статьи собраны по устойчивому шаблону, разделы почти всегда одни и те же: *Сюжет*, *В ролях*, *Съёмочная группа*, *Создание*, *Критика*, *Награды*, *Примечания*, *Литература*, *Ссылки*. Три последних раздела — списки источников и внешних адресов, к содержанию документа они отношения не имеют.

Кино-Театр.Ру, кодировка **windows-1251**. Это первое, обо что спотыкаешься: при чтении в UTF-8 весь текст превращается в мусор. Шаблона у статей нет, это обычный авторский текст с подзаголовками; биографии и карточки фильмов устроены проще — несколько абзацев плюс фильмография списком.

Разметка

Обе площадки отдают обычный HTML, текст виден прямо в исходном коде страницы. Основной текст лежит в одном контейнере: у Википедии это `<div class="mw-content-ltr mw-parser-output»`, у Кино-Театр.Ру — `<div class="art article_text»`. Всё, что вне контейнера, — меню, боковые панели и подвал.

Внутри текста у Википедии встречаются карточка фильма (`<table class="infobox»`) со структурированными полями, оглавление, сноски `<sup class="reference»` и заголовки разделов `<h2>`.

Дополнительная мета-информация

У Википедии: канонический адрес `<link rel="canonical»` и блок JS-конфигурации с внутренним номером статьи `wgArticleId` и полным списком её категорий `wgCategories` — фактически готовая рубрикация. Даты документа в HTML нет.

У Кино-Театр.Ру мета-информации больше: набор Open Graph (`og:title`, `og:description`, `og:url`, `og:image`), микроразметка schema.org через `itemprop` и точная дата публикации `datePublished`.

2 Разбиение на документы и выделение текста

За документ принята одна веб-страница — статья о фильме, о сериале, биография или авторский материал. Такое разбиение напрашивается само: каждая сущность на обеих площадках уже живёт по собственному адресу.

Для анализа вручную сохранено 12 страниц: 7 из Википедии и 5 с Кино-Театр.Ру. Брались документы разных типов и разного объёма — большие статьи, две заглушки, сериал, биографии, авторская статья.

Текст выделялся так: берётся содержимое основного контейнера, из него выбрасываются `<script>`, `<style>` и таблицы, снимаются остальные теги, раскрываются HTML-сущности, схлопываются пробелы.

Способ грубый. Выбрасывая таблицы, мы теряем вместе с версткой и карточку фильма с полезными полями (год, страна, режиссёр); зато разделы *Примечания* и *Ссылки* в текст попадают, хотя это библиографический шум. Для оценки корпуса этого достаточно, при индексации правила придётся уточнять.

3 Результаты

Количество документов

Объём корпуса оценён по счётчикам алфавитных категорий русской Википедии (таблица 1). Вложенные подкатегории не обходились, поэтому это нижняя оценка.

Категория	**Статей**
Фильмы по алфавиту	38 118
Актёры по алфавиту	15 563
Сценаристы по алфавиту	6 735
Кинорежиссёры по алфавиту	5 502
Телесериалы по алфавиту	5 148
Мультфильмы по алфавиту	4 322
Итого	**75 388**

Таблица 1: Объём кинотематики в русской Википедии

Требование в 30 000 документов перекрыто больше чем вдвое одним только первым источником. Точное число документов на Кино-Театр.Ру сайт не публикует, но по номерам страниц речь идёт как минимум о десятках тысяч записей.

Размеры документов

Измерения по 12 сохранённым страницам приведены в таблице 2. Под «сырым» размером понимается HTML-файл целиком, под текстом — то, что осталось после выделения.

Средние значения сведены в таблицу 3.

Самое заметное здесь — доля полезного текста: у Википедии в среднем 12 %, а у статей-заглушек всего 1 %. Причина в оформлении: тема встраивает в каждую страницу около полумегабайта меню и скриптов независимо от длины статьи. Поэтому судить об объёме будущего индекса по весу скачанных данных нельзя.

Документ	Сырой, КБ	Символов	Слов	Доля
ru.wikipedia.org				
Во все тяжкие (сериал)	1152,3	160 967	18 132	18,9 %
Янковский, Олег Иванович	1011,4	134 491	17 757	21,5 %
Тарковский, Андрей Арс.	706,1	65 359	9 566	15,2 %
Криминальное чтиво	633,4	42 945	6 860	10,3 %
Сталкер (фильм)	523,3	45 532	6 965	14,6 %
13 дней во Франции	119,9	745	133	1,0 %
24 недели	100,4	873	120	1,3 %
www.kino-teatr.ru				
Статья «Место встречи...»	105,3	18 950	2 711	32,0 %
Обзор сериала «Число зверя»	92,5	11 433	1 650	21,9 %
Биография: А. Мельникова	81,8	9 374	1 265	20,1 %
Карточка фильма	82,1	8 181	1 144	17,4 %
Биография: Д. Мухамадеев	80,3	8 320	1 137	18,2 %

Таблица 2: Размеры «сырых» документов и выделенного текста

Показатель	Википедия	Кино-Театр.Ру
Документов в выборке	7	5
Средний размер «сырого» документа, КБ	606,7	88,4
Средний объём текста, символов	64 416	11 252
Средний объём текста, слов	8 505	1 581
Средняя доля полезного текста	11,8 %	21,9 %

Таблица 3: Средние характеристики документа

4 Существующие поисковые системы

По корпусу уже можно искать встроенным поиском Википедии и поиском Google или Яндекса с ограничением `site:`. Значит, будет с чем сравнивать качество собственной системы.

Ниже — реальные запросы к встроенному поиску Википедии.

[я требую продолжения банкета] — точная цитата из фильма «Иван Васильевич меняет профессию». Выдача: *Иван Васильевич (пьеса)*, *Революция 1848 года во Франции*, *Скорая помощь*, *Тёмный рыцарь*, *Магическая битва*. Статьи о фильме нет вообще, со второй позиции — шум: революция 1848 года попала сюда по одному слову «банкет». Слова запроса ищутся независимо, цитата не распознаётся как цитата.

[фильм где мужик теряет память] — описательный запрос. Выдача: *Иди и смотри*, *Высота*, *Идиот (роман)* и две биографии актёров. Ни одного правильного ответа: поиск сцепился за слова «фильм» и «память», смысл описания прошёл мимо,

разговорное «мужик» ни с чем не сопоставлено.

[кто играл шерлока холмса в советском кино] — выдача: *Приключения Шерлока Холмса и доктора Ватсона*, *Майкрофт Холмс*, *Шерлок Холмс (сериал, 2013)*, *Клюев Б. В.*, *Доктор Ватсон*. Первый документ верный, но статьи о Василии Ливанове в пятёрке нет, зато есть исполнитель роли Майкрофта. Слова «кто» и «в» не отброшены как стоп-слова, а британский сериал 2013 года противоречит уточнению «в советском».

[фильм про зону и сталкера] — выдача: *Сталкер (фильм)*, *Сталкер*, *Пикник на обочине*, *Зона отчуждения ЧАЭС*, *S.T.A.L.K.E.R.* Здесь всё хорошо. Запрос такой же описательный, как второй, но в нём есть редкое слово «сталкер». Видно закономерность: на редких информативных терминах поиск справляется, на частотных словах общего языка — разваливается.

5 Выводы

Корпус выбран: кино и сериалы, два источника — русская Википедия и Кино-Театр.Ру. Документов хватает с запасом, готовые поисковые системы для сравнения есть.

Главное, что я вынес из работы: «размер документа» — не одна величина, а три. У статьи «Во все тяжкие» это 1152 КБ сырого HTML, 161 КБ текста и 18 тысяч слов, причём отношение между ними непостоянно — от 1 % у заглушек до 32 % у авторской статьи.

Ещё два наблюдения. Статьи-заглушки формально относятся к нужной тематике, но 120 слов текста делают их бесполезными и занижают все средние — отсеивать их надо сразу. И кодировки у источников разные: пока не заметишь windows-1251 на Кино-Театр.Ру, текст оттуда выглядит нечитаемым мусором.

Недостатки работы

Выборка маленькая — 12 документов, из них 5 по второму источнику, и отбирались они не случайно, а специально разнотипными. Средние по такой выборке неустойчивы, тем более при большом разбросе размеров. Метод выделения текста грубый: теряется карточка фильма, зато в текст попадают списки источников. Объём второго источника остался неизвестным.

Всё это стоит пересчитать по полному корпусу, когда он будет собран, и перейти от средних к медианам.

Список литературы

[1] Маннинг К. Д., Рагхаван П., Шютце Х. *Введение в информационный поиск* — М.: Издательский дом «Вильямс», 2011. — 528 с. — ISBN 978-5-8459-1623-4.

[2] Русская Википедия [Электронный ресурс]. — URL: https://ru.wikipedia.org/ (дата обращения: 19.09.2026).

[3] Кино-Театр.Ру [Электронный ресурс]. — URL: https://www.kino-teatr.ru/ (дата обращения: 19.09.2026).