Московский авиационный институт
(национальный исследовательский университет)

Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №1 по курсу «Информационный поиск»

«Добыча корпуса документов»

Студент: В. О. Горячкин
Преподаватель: А. А. Кухтичев
Группа: М8О-407Б-23
Дата: 21.10.2026
Оценка:
Подпись:

Москва, 2026

Лабораторная работа №1
«Добыча корпуса документов»

Необходимо проанализировать корпус документов, который будет использован при выполнении остальных лабораторных работ:

- скачать примеры документов к себе на компьютер и указать в отчёте источник данных; источников в итоговом индексе должно быть не менее двух;
- ознакомиться с корпусом, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если есть разметка текста, какая она?
- выделить текст;
- найти существующие поисковики, которые уже можно использовать для поиска по выбранному набору документов (встроенный поиск Википедии, поиск Google с ограничением на сайт);
- привести несколько примеров запросов к существующим поисковикам и указать недостатки в полученной выдаче.

В результатах работы должна быть указана статистическая информация о корпусе: размер примеров «сырых» документов, количество документов, размер текста, выделенного из «сырых» данных, средний размер документа и средний объём текста в документе.

1 Корпус и его характеристики

Тематика корпуса — **кино и сериалы**: фильмы, сериалы, мультфильмы и кинематографические персоналии. Источника два:

- **ru.wikipedia.org** — энциклопедические статьи о фильмах, сериалах и кинематографистах;
- **www.film.ru** — рецензии на фильмы и сериалы, тематические подборки и интервью.

Источники дополняют друг друга по жанру текста: энциклопедическая статья сообщает факты о фильме, рецензия — мнение о нём. Для поиска это разные запросы: «кто снял» и «стоит ли смотреть».

Из чего состоит текст

Википедия, кодировка UTF-8. Статьи собраны по устойчивому шаблону, разделы почти всегда одни и те же: *Сюжет*, *В ролях*, *Съёмочная группа*, *Создание*, *Критика*, *Награды*, *Примечания*, *Литература*, *Ссылки*. Три последних раздела — списки источников и внешних адресов, к содержанию документа они отношения не имеют.

film.ru, кодировка UTF-8. Статья — сплошной авторский текст из нескольких абзацев без подзаголовков, с иллюстрациями между ними; в конце стоит подпись автора и кнопки «Поделиться». Подборки устроены как нумерованный список фильмов с абзацем текста о каждом, интервью — как чередование вопросов и ответов. Кроме статей на сайте есть карточки фильмов, но текста в них — один-два абзаца аннотации.

Разметка

Обе площадки отдают обычный HTML, текст виден прямо в исходном коде страницы. Основной текст лежит в одном контейнере: у Википедии это `<div class="mw-content-ltr mw-parser-output">`, у film.ru — `<div class="wrapper_articles_text">` у статей и `<div class="wrapper_movies_text">` у карточек фильмов. Всё, что вне контейнера, — меню, боковые панели, комментарии и подвал.

Внутри текста у Википедии встречаются карточка фильма (`<table class="infobox">`) со структурированными полями, оглавление, сноски `<sup class="reference">` и заголовки разделов `<h2>`. У film.ru внутри контейнера только абзацы `<p>`, выделения `<strong>` и картинки.

Дополнительная мета-информация

У Википедии: канонический адрес `<link rel="canonical">` и блок JS-конфигурации с внутренним номером статьи `wgArticleId` и полным списком её категорий `wgCategories` — фактически готовая рубрикация. Даты документа в HTML нет.

У film.ru мета-информации больше. Кроме набора Open Graph (`og:title`, `og:description`, `og:url`, `og:image`) в странице есть разметка schema.org в формате JSON-LD: у рецензии — тип `Review` с автором, точной датой публикации `datePublished`, оценкой фильма по десятибалльной шкале и описанием самого фильма (`Movie`) с режиссёром и актёрами.

Почему не Кино-Театр.Ру

Первым кандидатом на второй источник был `www.kino-teatr.ru`: карточки фильмов, биографии актёров и авторские статьи. Пять его страниц сохранены в `samples/kinoteatr`, и по ним видны две его особенности. Он отдаёт страницы в **windows-1251** — при чтении в UTF-8 весь текст превращается в мусор. И содержательный текст там есть только у статей: биографии и карточки фильмов — это несколько предложений, от 8 до 46 слов.

От источника пришлось отказаться при обкачке во второй лабораторной работе: сайт закрыт защитой ddos-guard, которая после примерно пятисот запросов отдаёт роботу капчу вместо страниц и не снимает блокировку часами. На ручном скачивании пяти страниц это не проявилось, поэтому второй источник стоит проверять серией запросов, а не одним.

2 Разбиение на документы и выделение текста

За документ принята одна веб-страница: у Википедии — статья о фильме, сериале или человеке, у film.ru — рецензия, подборка или интервью. Такое разбиение напрашивается само: каждая сущность на обеих площадках уже живёт по собственному адресу.

Карточки фильмов film.ru документами не считаются. Текста в них — одна аннотация на несколько десятков слов, а всё остальное (актёры, рейтинги, расписание показов) — структурированные поля, которые лучше брать из метаданных, а не из текста.

Для анализа вручную сохранено 13 страниц: 7 из Википедии и 6 с film.ru. Брались документы разных типов и разного объёма: в Википедии — статьи о двух фильмах, две заглушки, сериал и две биографии; на film.ru — три рецензии разной длины, подборка, интервью и одна карточка фильма для сравнения.

Текст выделялся так: берётся содержимое основного контейнера, из него выбрасываются `<script>`, `<style>` и таблицы, снимаются остальные теги, раскрываются HTML-сущности, схлопываются пробелы.

Способ грубый. Выбрасывая таблицы, мы теряем вместе с версткой и карточку фильма с полезными полями (год, страна, режиссёр); зато разделы *Примечания* и *Ссылки* в текст попадают, хотя это библиографический шум. Для оценки корпуса этого достаточно, при индексации правила придётся уточнять.

3 Результаты

Количество документов

Объём корпуса оценён по счётчикам алфавитных категорий русской Википедии (таблица 1). Вложенные подкатегории не обходились, поэтому это нижняя оценка.

Категория	**Статей**
Фильмы по алфавиту	38 118
Актёры по алфавиту	15 563
Сценаристы по алфавиту	6 735
Кинорежиссёры по алфавиту	5 502
Телесериалы по алфавиту	5 148
Мультфильмы по алфавиту	4 322
Итого	**75 388**

Таблица 1: Объём кинотематики в русской Википедии

Требование в 30 000 документов перекрыто больше чем вдвое одним только первым источником.

У film.ru статьи собраны в три раздела-списка по 28 статей на странице: рецензии — 324 страницы, подборки — 187, интервью — 34. Номер последней страницы найден перебором: следующая за ней отвечает 404. Получается около 15 тысяч статей. Вместе с Википедией корпус заведомо больше требуемых 30 тысяч, даже с учётом того, что часть статей окажется заглушками.

Размеры документов

Измерения по 13 сохранённым страницам приведены в таблице 2. Под «сырым» размером понимается HTML-файл целиком, под текстом — то, что осталось после выделения. Доля — объём текста в байтах к размеру страницы; оба источника отдают UTF-8, так что байты считаются одинаково.

Средние значения сведены в таблицу 3. Карточка фильма film.ru в средние не входит: документом она не считается и приведена только для сравнения.

Самое заметное здесь — доля полезного текста: у Википедии в среднем 12 %, а у статей-заглушек всего 1 %. Причина в оформлении: тема встраивает в каждую страницу около полумегабайта меню и скриптов независимо от длины статьи. Поэтому судить об объёме будущего индекса по весу скачанных данных нельзя.

У film.ru картина другая: страницы в пять раз легче, а статьи короче, но ровнее — от 600 до 2 400 слов, заглушек в выборке нет. Доля текста при этом даже выше, чем

Документ	Сырой, КБ	Символов	Слов	Доля
ru.wikipedia.org				
Во все тяжкие (сериал)	1152,3	161 473	18 159	18,9 %
Янковский, Олег Иванович	1011,4	135 005	17 758	21,5 %
Тарковский, Андрей Арс.	706,1	65 397	9 568	15,3 %
Криминальное чтиво	633,4	42 958	6 866	10,3 %
Сталкер (фильм)	523,3	45 539	6 967	14,6 %
13 дней во Франции	119,9	745	133	1,0 %
24 недели	100,4	873	120	1,3 %
www.film.ru				
Интервью о кинопрокате	122,1	16 115	2 456	23,4 %
Рейтинг сериалов М. Флэнагана	137,7	12 219	1 750	15,7 %
Обзор сериала «Полураспад»	116,8	7 206	980	11,0 %
Рецензия «Последнее дело Холмса»	107,9	5 182	741	8,6 %
Рецензия на фильм «Животные»	111,7	4 579	628	7,3 %
Карточка фильма	149,1	369	52	0,4 %

Таблица 2: Размеры «сырых» документов и выделенного текста

Показатель	Википедия	film.ru
Документов в выборке	7	5
Средний размер «сырого» документа, КБ	606,7	119,2
Средний объём текста, символов	64 570	9 060
Средний объём текста, слов	8 510	1 311
Средняя доля полезного текста	11,9 %	13,2 %

Таблица 3: Средние характеристики документа

у Википедии. Карточка фильма весит больше любой статьи, а текста в ней 52 слова — поэтому карточки и не взяты в корпус.

4 Существующие поисковые системы

По корпусу уже можно искать встроенным поиском Википедии, собственным поиском film.ru (форма на каждой странице сайта) и поиском Google или Яндекса с ограничением `site:`. Значит, будет с чем сравнивать качество собственной системы.

Ниже — реальные запросы к встроенному поиску Википедии.

[я требую продолжения банкета] — точная цитата из фильма «Иван Васильевич меняет профессию». Выдача: *Иван Васильевич (пьеса)*, *Революция 1848 года во Франции*, *Скорая помощь*, *Тёмный рыцарь*, *Магическая битва*. Статьи о фильме нет вообще, со второй позиции — шум: революция 1848 года попала сюда по одному слову «банкет». Слова запроса ищутся независимо, цитата не распознаётся как цитата.

[фильм где мужик теряет память] — описательный запрос. Выдача: *Иди и смотри*, *Высота*, *Идиот (роман)* и две биографии актёров. Ни одного правильного ответа: поиск сцепился за слова «фильм» и «память», смысл описания прошёл мимо, разговорное «мужик» ни с чем не сопоставлено.

[кто играл шерлока холмса в советском кино] — выдача: *Приключения Шерлока Холмса и доктора Ватсона*, *Майкрофт Холмс*, *Шерлок Холмс (сериал, 2013)*, *Клюев Б. В.*, *Доктор Ватсон*. Первый документ верный, но статьи о Василии Ливанове в пятёрке нет, зато есть исполнитель роли Майкрофта. Слова «кто» и «в» не отброшены как стоп-слова, а британский сериал 2013 года противоречит уточнению «в советском».

[фильм про зону и сталкера] — выдача: *Сталкер (фильм)*, *Сталкер*, *Пикник на обочине*, *Зона отчуждения ЧАЭС*, *S.T.A.L.K.E.R.* Здесь всё хорошо. Запрос такой же описательный, как второй, но в нём есть редкое слово «сталкер». Видно закономерность: на редких информативных терминах поиск справляется, на частотных словах общего языка — разваливается.

5 Выводы

Корпус выбран: кино и сериалы, два источника — русская Википедия и film.ru. Они дополняют друг друга: энциклопедические статьи и авторские рецензии. Документов хватает с запасом, готовые поисковые системы для сравнения есть.

Главное, что я вынес из работы: «размер документа» — не одна величина, а три. У статьи «Во все тяжкие» это 1152 КБ сырого HTML, 161 тысяча символов текста и 18 тысяч слов, причём отношение между ними непостоянно — от 0,4 % у карточки фильма на film.ru до 23,4 % у интервью там же.

Ещё два наблюдения. Статьи-заглушки Википедии и карточки фильмов film.ru формально относятся к нужной тематике, но 50–130 слов текста делают их бесполезными и занижают все средние — отсеивать их надо сразу. И второй источник нельзя выбирать по пяти скачанным вручную страницам: Кино-Театр.Ру на них выглядел подходящим, а при обкачке закрылся от робота капчей.

Недостатки работы

Выборка маленькая — 13 страниц, из них 6 по второму источнику, и отбирались они не случайно, а специально разнотипными. Средние по такой выборке неустойчивы, тем более при большом разбросе размеров. Метод выделения текста грубый: теряется карточка фильма, зато в текст попадают списки источников. Объём film.ru оценён по числу страниц в списках, а не по реально скачанным документам.

Всё это стоит пересчитать по полному корпусу, когда он будет собран, и перейти от средних к медианам.

Список литературы

[1] Маннинг К. Д., Рагхаван П., Шютце Х. *Введение в информационный поиск* — М.: Издательский дом «Вильямс», 2011. — 528 с. — ISBN 978-5-8459-1623-4.

[2] Русская Википедия [Электронный ресурс]. — URL: https://ru.wikipedia.org/ (дата обращения: 19.09.2026).

[3] Film.ru [Электронный ресурс]. — URL: https://www.film.ru/ (дата обращения: 18.10.2026).

[4] Кино-Театр.Ру [Электронный ресурс]. — URL: https://www.kino-teatr.ru/ (дата обращения: 19.09.2026).